SERI DATA DETECTIVE

MODUL MATERI 1

IDENTIFIKASI DATA

Mengenali dan mencatat masalah data.

A. Pengantar dan Definisi

Dalam era digital saat ini, data merupakan aset yang sangat berharga bagi berbagai organisasi dan lembaga. Namun, data yang dikumpulkan tidak selalu dalam kondisi sempurna. Seringkali terdapat kesalahan penginputan, ketidaklengkapan informasi, atau inkonsistensi format yang dapat mengurangi kualitas data secara keseluruhan.

Sebelum data dapat diolah dan dianalisis lebih lanjut, diperlukan suatu proses pemeriksaan awal yang disebut **identifikasi data**. Proses ini bertujuan untuk menemukan dan mencatat seluruh permasalahan yang ada dalam kumpulan data, sehingga langkah perbaikan dapat dilakukan secara tepat dan terarah

Identifikasi data adalah proses sistematis untuk mengenali, menemukan, dan mencatat data yang bermasalah, tidak lengkap, tidak konsisten, atau tidak sesuai dengan aturan dan standar yang berlaku dalam suatu kumpulan data, sebelum data tersebut diproses lebih lanjut.

Tujuan utama: Memastikan bahwa data yang akan diolah telah memenuhi syarat kualitas minimum sehingga hasil pengolahan dapat diandalkan

B. Mengapa Identifikasi Data Penting?

Dalam ilmu komputer dan pengolahan informasi, terdapat sebuah prinsip dasar yang dikenal luas, yaitu **GIGO (Garbage In, Garbage Out)**. Prinsip ini menyatakan bahwa kualitas output dari suatu sistem informasi sepenuhnya bergantung pada kualitas data yang menjadi inputnya.

Apabila data yang dimasukkan ke dalam sistem berkualitas buruk (tidak lengkap, tidak akurat, atau tidak konsisten), maka informasi yang dihasilkan pun akan berkualitas buruk dan tidak dapat dijadikan dasar pengambilan keputusan yang tepat. Sebaliknya, data yang bersih, lengkap, dan akurat akan menghasilkan informasi yang andal dan bernilai tinggi.

Dampak Negatif Apabila Identifikasi Data Tidak Dilakukan:

✗ **Pengambilan Keputusan yang keliru**

Data yang tidak akurat menghasilkan informasi yang menyesatkan. Keputusan yang diambil berdasarkan informasi tersebut berpotensi merugikan organisasi secara signifikan

✗ **Pemborosan Sumber Daya**

Menemukan dan memperbaiki kesalahan di tengah proses pengolahan dara memerlukan waktu dan biaya yang jauh lebih besar dibandingkan jika kesalahan ditemukan sejak awal

✗ **Hilangnya Kepercayaan Pengguna**

Sistem informasi yang menghasilkan laporan yang sering keliru akan kehilangan kepercayaan dari pengguna sehingga tidak lagi digunakan secara optimal

✗ **Dampak Berantai pada Sistem Lain**

Dalam sistem informasi modern, satu basis data sering menjadi sumber bagi banyak sistem lain. Data yang salah pada satu sumber dapat menyebabkan kesalahan berantai pada seluruh sistem yang bergantung

C. Jenis-Jenis Masalah Data

1. Data Tidak Lengkap (Missing/Incomplete Data)

Data tidak lengkap terjadi apabila satu atau lebih kolom yang diwajibkan untuk diisi ternyata kosong atau tidak memiliki nilai. Setiap atribut yang bersifat *mandatory* (wajib) tidak boleh dibiarkan kosong karena dapat menyebabkan kesalahan dalam proses komputasi dan analisis.

Contoh pada Data Siswa:

✗ **Bermasalah**	*NIS*: 2024003 I *Nama*: (kosong) I *Tgl* : 15/01/2008	Kolom Nama Wajib diisi
✔ **Baik**	*NIS: 2024003* | *Nama: Citra Lestari* | *Tgl: 15/01/2008*	Semua kolom terisi

- **Contoh pada Data Lain:** Data transaksi — No. Faktur: INV-001 | Nama Pembeli: (kosong) | Total: Rp 250.000.

Kesalahan pada data: Kolom Nama Pembeli wajib diisi untuk keperluan administrasi dan pelaporan keuangan.

- **Cara Menemukan:** Periksa setiap baris secara menyeluruh dan tandai sel yang tidak memiliki nilai pada kolom-kolom yang bersifat wajib

2. Format Tidak Konsisten (Inconsistent Format)

Format tidak konsisten terjadi ketika data memiliki cara penulisan yang berbeda-beda untuk informasi yang seharusnya mengikuti satu standar yang sama. Inkonsistensi format menyulitkan proses pengurutan, pencarian, dan pembandingan data secara otomatis

Contoh pada Data Siswa:

- **Format Penulisan Tanggal yang Ditentukan: DD/MM/YYYY**

✗ **Bermasalah**	*Tgl Lahir: 2008-07-15 (format YYYY-MM-DD)*	Seharusnya DD/MM/YYYY
✔ **Baik**	*Tgl Lahir: 15/07/2008 (format DD/MM/YYYY)*	Format standar terpenuhi

- **Contoh pada Data Lain:** Data produk toko - Harga tercatat sebagai: ‘Rp25000’, ‘Rp 25.000’, ‘25000’, ‘IDR 25,000’

Kesalahan pada data: Keempat nilai mempresentasikan jumlah yang sama namun ditulis berbeda, sehingga sistem tidak dapat membandingkannya secara otomatis

- **Cara Menemukan:** Tetapkan format standar untuk setiap kolom, kemudian bandingkan setiap nilai dengan standar tersebut. perhatikan terutama kolom tanggal, kode, dan identitas

3. Data Duplikat (Duplicate Data)

Data duplikat adalah kondisi di mana satu entitas yang sama tercatat lebih dari satu kali dalam kumpulan data. Duplikasi umumnya terjadi akibat kesalahan input, penggabungan dari beberapa sumber, atau kegagalan sistem. Keberadaanya dapat mengacaukan hasil perhitungan dan analisis statistika.

Contoh pada Data Siswa:

✔ **Baris 1 (Asli)**	*NIS: 2024001 | Nama: Andi Wijaya | Kelas: X-TKJ*	Data pertama - valid
✗ **Baris 4 (Duplikat)**	*NIS: 2024001 | Nama: Andi Wijaya | Kelas: X-TKJ*	Data keempat - Duplikat

- **Contoh pada Data Lain:** Data inventaris barang - Terdapat dua entri data barang yang memiliki ID stok barang berbeda yaitu “ST001” dan “ST009”, namun menggunakan kode barang yang sama, yaitu “BRG001” (LAPTOP ASUS).

Kesalahan pada data: Satu produk dengan kode yang sama tercatat dua kali dengan ID stok

barang yang berbeda dalam sistem inventaris. Kondisi ini menyebabkan sistem menganggap kedua data tersebut sebagai barang yang berbeda, sehingga toral stok menjadi tidak akurat dan berpotensi menimbulkan kesalahan dalam proses distribusi

- **Cara Menemukan:** Cari baris dengan NIS yang sama, atau nama dan tanggal lahir yang identik

4. Data Tidak Valid (Invalid Data)

Data tidak valid adalah data yang memiliki nilai yang secara teknis tersimpan dalam sistem, namun tidak memenuhi aturan bisnis atau batasan nilai yang ditetapkan. Berbeda dengan dara tidak lengkap yang kosong, data tidak valid memiliki nilai namun nilai tersebut salah atau tidak sesuai aturan.

Contoh pada Data Siswa:

✗ **Bermasalah**	*Nama*: 'Budi 123' I *No Telp: 08133445* I *Kelas: XTKJ*	Nama ada angka; No Telp kurang dari 8 Digit; Kelas tidak ada tanda hubung '-'
✔ **Baik**	*Nama: 'Budi Santoso'* | *No Telp: 081334456789* | *Kelas: X-TKJ*	Semua nilai sesuai aturan

- **Contoh pada Data Lain:** Data stok produk - Jumlah stok: -15 unit (nilai negatif tidak logis). Atau data pegawai - Tgl lahir: 30/02/2000 (tanggal 30 Februari tidak ada dalam kalender)

Kesalahan pada data: Data stok produk ditulis dengan nilai negatif yang seharusnya data stok barang bernilai 0 apabila stok habis. Sementara untuk data pegawai ditulis dengan tanggal diluar kalender.

- **Cara Menemukan:** Bandingkan nilai setiap kolom dengan aturan validasi yang berlaku: tipe data, panjang karakter, rentang nilai, dan pola format yang diizinkan.

D. Contoh Kasus: Identifikasi Data Siswa

Berikut adalah contoh kumpulan data siswa yang perlu diperiksa. Perhatikan setiap baris secara teliti dan temukan seluruh permasalahan yang ada sebelum melihat analisisnya.

No	NIS	NAMA	TGL LAHIR	KELAS	NO TELP
1	2024001	Andi Wijaya	12/05/2008	X - TKJ	08123456789
2	2024002	Budi 123	10/10/2009	X - TKJ	08199867766
3	2024003	(Kosong)	15/01/2008	X - TKJ	08521234432

4	2024001	Andi Wijaya	12/05/2008	X - TKJ	08123456789
5	2024005	Dewi Sartika	22/03/2010	XTKJ	08123456781
6	2024006	Eko Prasetyo	05/12/2007	X - TKJ	08133445
7	2024007	Fani Rahayu	2008-07-15	X - TKJ	08133344455

Keterangan warna: ■ Merah = Data Bermasalah ■ Kuning = Perlu Diperhatikan

Analisis Masalah pada Data di Atas

No	Baris	Kolom Bermasalah	Jenis Masalah	Keterangan
1	Baris 2	Nama	Data Tidak Valid	Nama 'Budi 123' mengandung angka — nama hanya boleh terdiri dari huruf dan spasi
2	Baris 3	Nama	Data Tidak Lengkap	Kolom Nama kosong, padahal merupakan kolom wajib yang harus diisi
3	Baris 4	Semua Kolom	Data Duplikat	NIS '2024001' sudah digunakan pada Baris 1 — setiap NIS harus bernilai unik
4	Baris 5	Kelas	Data tidak Valid	'XTKJ' tidak sesuai format standar kelas 'X-TKJ' (kurang tanda hubung '-')
5	Baris 6	No Telp	Data tidak Valid	'08133445' hanya 8 digit — nomor telepon harus terdiri dari 10 hingga 12 digit
6	Baris 7	Tgl Lahir	Format Tidak Konsisten	'2008-07-15' menggunakan format YYYY-MM-DD, bukan format standar DD/MM/YYYY

E. Hubungan Identifikasi Data dengan Tahap Pengolahan Data Lainnya

Identifikasi data merupakan tahap pertama dari empat tahapan utama dalam siklus pengolahan data. keempat tahapan ini bersifat berurutan dan saling bergantung – kualitas setiap tahap mempengaruhi efektivitas tahap berikutnya:

1 **Tahap 1 : Identifikasi Data**
Menemukan dan mencatat data yang bermasalah, tidak lengkap, tidak konsisten, atau tidak valid.
→ *Output: Daftar masalah data yang lengkap dan terstruktur*

2 **Tahap 2: Validasi Data**
Memeriksa apakah setiap data telah memenuhi aturan dan standar yang telah ditetapkan (format, tipe data, rentang nilai).
→ *Output: Status Validasi setiap entri data*

3 **Tahap 3: Verifikasi Data**
Membandingkan data input dengan data referensi atau sumber terpercaya untuk

memastikan kebenaran isinya.
→ *Output: Konfirmasi Kebenaran data dengan membandingkan sumber aslinya*

4 **Tahap 4: Pembersihan Data**
Memperbaiki, mengedit, atau menghapus data bermasalah berdasarkan hasil identifikasi, validasi, dan verifikasi
→ *Output: Data yang bersih, lengkap, dan siap dianalisis*

Identifikasi data data menghasilkan **daftar masalah** yang menjadi acuan pada tahap validasi. Validasi menghasilkan **status data** yang digunakan dalam verifikasi. Verifikasi mengkonfirmasi **kebenaran data** sebelum dilakukan pembersihan. Tanpa identifikasi yang menyeluruh di tahap pertama, seluruh proses berikutnya beresiko melewatkan masalah yang seharusnya diperbaiki.

F. Langkah-Langkah Identifikasi Data

Proses identifikasi data harus dilakukan secara sistematis dan terurut agar tidak ada masalah yang terlewat. Berikut adalah panduan langkah demi langkah dalam melakukan identifikasi data

1 **Tentukan Aturan dan Standar Data**
Sebelum memeriksa data, pahami dan dokumentasikan seluruh aturan yang berlaku untuk setiap kolom. Contoh aturan: NIS harus 7 digit angka; Nama hanya boleh menggunakan huruf dan spasi; Tanggal lahir berformat DD/MM/YYYY; Kelas berformat X-XXX; Nomor telepon 10-12 digit diawali '08'.

2 **Periksa Kelengkapan Data**
Periksa setiap baris apakah seluruh kolom wajib telah terisi dengan nilai yang sesungguhnya. Kolom yang kosong atau hanya berisi simbol pengganti (seperti '-', 'N/A') perlu dicatat sebagai data tidak lengkap.

3 **Periksa Konsistensi Format**
Bandingkan format penulisan setiap nilai dengan standar yang telah ditetapkan. Fokuskan perhatian pada kolom yang rawan inkonsistensi seperti tanggal, kode kelas, dan nomor identitas.

4 **Identifikasi Data Duplikat**
Periksa seluruh kolom yang berfungsi sebagai identifikasi unik (primary key, seperti NIS atau ID Pelanggan) untuk menemukan nilai yang muncul lebih dari satu kali. Catat baris yang dianggap asli dan baris yang merupakan duplikat.

5 **Validasi Nilai Data**
Periksa apakah setiap nilai berada dalam rentang dan kategori yang diizinkan. Nama tidak boleh mengandung angka; nomor telepon harus mencukupi jumlah digitnya; kode kelas harus sesuai dengan daftar yang tersedia.

6 **Dokumentasi Seluruh Temuan**
Catat seluruh temuan secara sistematis: baris mana yang bermasalah, kolom mana

yang bermasalah, kategori masalahnya, dan nilai yang seharusnya (bila diketahui). Dokumentasi ini menjadi dasar pada tahap validasi, verifikasi, dan pembersihan data berikutnya.

G. Ringkasan

1. Identifikasi data adalah langkah pertama dalam proses pengolahan data yang bertujuan menemukan data bermasalah sebelum diolah .
2. Prinsip GIGO (Garbage In, Garbage Out) mengingatkan kita bahwa kualitas hasil pengolahan bergantung pada kualitas data yang dimasukkan.
3. Ada empat jenis masalah utama yang perlu dikenali: data tidak lengkap, format tidak konsisten, data duplikat, dan data tidak valid.
4. Identifikasi data dilakukan secara sistematis dengan mengikuti langkah-langkah: tentukan aturan → periksa kelengkapan → periksa format → cari duplikat → validasi nilai → catat masalah
5. Hasil identifikasi data menjadi dasar untuk tahap selanjutnya, yaitu validasi data, verifikasi data, dan pembersihan data.