SERI DATA DETECTIVE

MODUL MATERI 4

PEMBERSIHAN DATA

Tindakan perbaikan data bermasalah.

A. Pengantar dan Definisi

Setelah tiga tahap sebelumnya — identifikasi, validasi, dan verifikasi — selesai dilaksanakan, kini seluruh permasalahan data telah tercatat dengan jelas beserta status dan detail perbaikan yang diperlukan. Tahap terakhir dalam siklus pengolahan data adalah **pembersihan data**, yaitu tahap di mana seluruh tindakan perbaikan dilaksanakan secara nyata terhadap data yang bermasalah.

Pembersihan data bukan sekadar menghapus data yang salah, melainkan melibatkan serangkaian tindakan yang berbeda-beda tergantung pada jenis dan tingkat keparahan masalah yang ditemukan. Pada tahap ini keputusan atau tindakan nyata harus diambil seperti: apakah suatu data akan dibiarkan apa adanya karena sudah benar, diperbaiki nilainya, dihapus karena tidak dapat diselamatkan, atau ditandai untuk ditindaklanjuti lebih lanjut oleh pihak yang berwenang. Setiap tindakan harus dilakukan dengan hati-hati dan berdasarkan panduan yang jelas agar tidak merusak integritas data yang sudah benar.

■ Definisi Pembersihan Data

Pembersihan data (*data cleansing* atau *data cleaning*) adalah proses memperbaiki, mengedit, atau menghapus data yang tidak akurat, tidak lengkap, tidak konsisten, atau tidak valid dalam suatu kumpulan data, berdasarkan hasil identifikasi, validasi, dan verifikasi yang telah dilakukan sebelumnya.

Tujuan akhir: Menghasilkan kumpulan data yang bersih, akurat, lengkap, konsisten, dan siap digunakan untuk analisis atau pengambilan keputusan.

Hasil pembersihan data: Setiap entri data akan diberikan salah satu dari empat status tindakan: Data Bersih, Data Diedit, Dihapus, atau Ditandai. Status ini mencerminkan tindakan yang diambil terhadap data tersebut dalam proses pembersihan.

B. Tujuan dan Pentingnya Pembersihan Data

Pembersihan data merupakan tahap yang paling konkret dalam siklus pengolahan data karena di sinilah perubahan nyata dilakukan terhadap data untuk meningkatkan kualitasnya. Tiga tahap sebelumnya bersifat diagnostik untuk menemukan dan menganalisis masalah sementara pembersihan data bersifat terapeutik yang memberikan solusi dan perbaikan. Tanpa pembersihan data yang tepat, seluruh upaya identifikasi, validasi, dan verifikasi yang telah dilakukan tidak akan memberikan manfaat yang nyata.

Tujuan Utama Pembersihan Data:

✓ **Meningkatkan Akurasi Data**
Memastikan bahwa setiap nilai dalam kumpulan data mencerminkan kondisi yang benar dan dapat diandalkan sebagai dasar analisis dan pelaporan.

✓ **Memastikan Konsistensi Data**
Memastikan bahwa seluruh data dalam kumpulan tersebut konsisten satu sama lain, tidak ada duplikasi yang tersisa, dan seluruh nilai memastikan standar kualitas yang telah ditetapkan.

✓ **Menghilangkan Redundansi**
Menghapus atau menggabungkan data duplikat sehingga setiap entitas hanya direpresentasikan satu kali dalam sistem, mencegah perhitungan ganda.

✓ **Melengkapi Data yang Tidak Lengkap**
Mengisi kolom-kolom yang masih kosong dengan nilai yang benar berdasarkan sumber referensi atau dengan menandai data tersebut untuk ditindaklanjuti.

✓ **Menghasilkan Data Siap Analisis**
Mengubah data mentah yang penuh permasalahan menjadi data bersih yang bebas dari kesalahan, duplikasi, dan ketidaklengkapan yang dapat mempengaruhi keakuratan hasil sehingga siap digunakan untuk analisis, pelaporan, dan pengambilan keputusan.

C. Jenis-Jenis Tindakan Pembersihan Data

Dalam proses pembersihan data, terdapat empat jenis tindakan yang dapat diterapkan. Pemilihan tindakan yang tepat bergantung pada jenis masalah yang ditemukan dan ketersediaan data yang benar sebagai pengganti.

1. Data Bersih

Status **Data Bersih** diberikan kepada entri data yang telah lolos seluruh tahap pemeriksaan (identifikasi, validasi, dan verifikasi) tanpa ditemukan masalah apapun. Data ini tidak memerlukan perubahan dan langsung dapat digunakan dalam proses analisis

Kondisi yang harus dipenuhi:

- ☐ Tidak ada masalah yang ditemukan pada tahap identifikasi
- ☐ Seluruh nilai memenuhi aturan validasi yang berlaku
- ☐ Seluruh isi data sesuai dengan data referensi yang terpercaya.

Contoh pada Data Siswa

Nama	NIS	Tgl Lahir	Kelas	No Telp	Status
Andi Wijaya	2024001	12/05/2008	X-TKJ	08123456789	✔ **Data Bersih**

Kesimpulan : Semua kolom valid dan sesuai referensi
Tindakan : Tidak ada perubahan yang perlu dilakukan. Data langsung ditandai sebagai bersih dan siap digunakan

2. Data Diedit

Status **Data Bersih** diberikan kepada entri data yang memiliki kesalahan yang dapat diperbaiki dengan mengganti nilai yang salah dengan nilai yang benar berdasarkan data referensi yang sah atau aturan yang telah ditetapkan. Data ini tidak perlu dihapus, tetapi nilainya perlu dikoreksi agar sesuai dengan standar dan referensi yang berlaku.

Kondisi yang memerlukan status ini:

- Ditemukan kesalahan format (misal: tanggal dengan format YYYY-MM-DD).
- Ditemukan nilai tidak valid yang dapat diperbaiki (misal: nama mengandung angka).
- Verifikasi menemukan perbedaan dengan referensi yang nilai sudah diketahui

Contoh pada Data Siswa

Kolom	Nilai Sebelum (Salah)	Nilai Sesudah (Benar)	Alasan perubahan
Nama	Budi123 santoso	Budi Santoso	Nama mengandung angka; sesuaikan dengan referensi wali kelas
Kelas	XTKJ	X-TKJ	Format kelas tidak konsisten, kurang tanda hubung '-'
Tgl Lahir	2008-07-15	15/07/2008	Format YYYY-MM-DD tidak sesuai standar DD/MM/YYYY

Kesimpulan : Penulisan masih tidak sesuai referensi dan aturan yang ditetapkan
Tindakan : Perbaikan nilai yang salah sesuai dengan data referensi atau aturan validasi yang berlaku. Catat nilai lama dan nilai baru sebagai dokumentasi perubahan.

3. Data Dihapus

Status **Data Dihapus** diberikan kepada entri data yang mengandung masalah yang tidak dapat diperbaiki atau merupakan duplikat yang jelas dari entri lain, sehingga lebih baik dihapus daripada dipertahankan dalam kumpulan data. Mempertahankan data yang tidak dapat diperbaiki justru akan menurunkan kualitas keseluruhan data.

Kondisi yang memerlukan status ini:

- Data duplikat yang merupakan salinan persis dari entri lain yang valid.
- Data yang tidak memiliki nilai apapun yang dapat diselamatkan dan berstatus 'Tidak bisa Diverifikasi'
- Data yang seluruh kolomnya kosong atau tidak berisi informasi yang bermakna.

Contoh pada Data Siswa

No	Nama	NIS	Tgl Lahir	Kelas	Alasan Dihapus
1	Andi Wijaya	2024001	12/05/2008	X-TKJ	-
2	Budi Santoso	2024002	15/07.2008	X-TKJ	-
3	Andi Wijaya	2024001	12/05/2008	X-TKJ	Duplikat dari baris 1 — NIS, nama, dan tgl lahir identik

Kesimpulan : Baris 3 merupakan data duplikat dari baris 1
Tindakan : Hapus entri dari kumpulan data. Pastikan bahwa entri asli yang valid tetap dipertahankan sebelum menghapus duplikatnya. Catat entri yang dihapus beserta alasannya sebagai dokumentasi.

4. Ditandai

Status **Ditandai** diberikan kepada entri data yang memiliki masalah namun belum dapat diselesaikan secara mandiri karena membutuhkan informasi tambahan, konfirmasi dari pihak lain, atau keputusan

dari pihak yang berwenang. Data ini tidak dihapus, tetapi juga tidak di edit sebelum ada kejelasan lebih lanjut

Kondisi yang memerlukan status ini:

- ☐ Data berstatus 'Tidak Bisa Diverifikasi' namun memiliki sebagian nilai yang mungkin masih berguna.
- ☐ Terdapat ketidaksesuaian yang memerlukan konfirmasi langsung dari pemilik data
- ☐ Terdapat data yang meragukan dan perlu investigasi lebih lanjut
- ☐ Sumber referensi memberikan dua atau lebih nilai yang berbeda dan belum bisa ditentukan mana yang benar

Contoh pada Data Siswa

Nama	NIS	Tgl Lahir	Kelas	Masalah	Tindak Lanjut
Andi Wijaya	2024001	12/05/2008	X-TKJ	-	-
Citra Dewi	2024001	23/06.2008	X-TKJ	NIS duplikat dengan Andi Wijaya dan data referensi tidak ditemukan	Konfirmasi ke bagian tata usaha sekolah

Kesimpulan : Terjadi duplikat pada data dan tidak ada data referensi
Tindakan : Beri tanda khusus pada entri dan catat masalah serta pihak yang perlu dikonfirmasi. Jangan mengedit atau menghapus data sebelum ada keputusan yang jelas

D. Kapan Menggunakan Setiap Tindakan

Pemilihan tindakan pembersihan yang tepat sangat penting untuk menjaga integritas data. Tabel berikut memberikan panduan singkat dalam memilih tindakan yang sesuai berdasarkan kondisi data yang ditemukan:

Kondisi Data	Nilai Benar Diketahui?	Ada Duplikat?	Tindakan yang Tepat
Semua kolom benar dan sesuai referensi	Ya	Tidak	✓ Data Bersih
Ada nilai yang salah (format, ejaan, isi)	Ya	Tidak	✏ Data Diedit
Entri duplikat persis dengan entri lain	Ya	Ya	✕ Data Dihapus
Ada kolom kosong, nilai benar tidak diketahui	Tidak	Tidak	■ Ditandai
Data tidak valid dan tidak bisa dipulihkan	Tidak	Tidak	✕ Data Dihapus
Data meragukan, perlu konfirmasi lebih lanjut	Belum pasti	Tidak	■ Ditandai

■ Peringatan Penting

Pembersihan data harus dilakukan dengan hati-hati dan berdasarkan bukti yang jelas. Jangan pernah menghapus data hanya karena tampak mencurigakan, dan jangan mengedit data berdasarkan asumsi tanpa konfirmasi dari sumber referensi. Setiap tindakan yang diambil harus dapat dipertanggungjawabkan.

Jika tindakan penghapusan data bersifat **permanen** dan tidak dapat dibatalkan. Pastikan bahwa data yang akan dihapus memang benar-benar tidak diperlukan dan merupakan duplikat atau data yang tidak valid.

Jika ragu antara menghapus atau menandai, selalu pilih **ditandai** terlebih dahulu untuk memberikan kesempatan konfirmasi sebelum data dihapus secara permanen.

E. Hubungan Pembersihan dengan Tahap Sebelumnya

Pembersihan data tidak dilakukan secara mandiri, melainkan sepenuhnya bergantung pada hasil dari tiga tahap sebelumnya. Setiap tindakan pembersihan harus dapat ditelusuri kembali ke temuan pada tahap identifikasi, validasi, atau verifikasi.

Identifikasi Data

Output: Menghasilkan daftar data bermasalah beserta kategori masalahnya.
Perannya dalam Pembersihan: Menentukan entri data mana saja yang perlu mendapatkan perhatian dan jenis masalah yang ditemukan.

▼

Validasi Data

Output: Menghasilkan status validasi setiap entri: valid, tidak valid (format/tipe/rentang), atau tidak lengkap.
Perannya dalam Pembersihan: Menentukan jenis masalah yang ada sehingga tindakan edit atau penandaan dapat dilakukan dengan tepat.

▼

Verifikasi Data

Output: Menghasilkan status verifikasi: Data Sudah Benar, Perlu Perbaikan, atau Tidak Bisa Diverifikasi.
Perannya dalam Pembersihan: Memberikan nilai yang benar (dari referensi) sebagai acuan dalam melakukan pengeditan data, dan mengidentifikasi data yang perlu ditandai .

▼

★ **Tahap Ini: Pembersihan Data**

Output: Menghasilkan kumpulan data yang bersih, akurat, dan siap digunakan untuk analisis.
Perannya dalam Pembersihan: Menerapkan seluruh temuan dari tiga tahap sebelumnya menjadi tindakan nyata yang menghasilkan data berkualitas tinggi

F. Contoh Kasus: Pembersihan Data Siswa

Berikut adalah contoh proses pembersihan data siswa yang dilakukan berdasarkan hasil identifikasi, validasi, dan verifikasi yang telah selesai dilaksanakan. Setiap entri diberikan tindakan pembersihan yang sesuai dengan masalah yang ditemukan.

Data Sebelum Pembersihan:

No	Nama	NIS	Tgl Lahir	Kelas	No Telp	Masalah Ditemukan
1	Andi Wijaya	2024001	12/05/2008	X-TKJ	08123456789	Tidak ada masalah
2	Budi123 Santoso	2024002	10/10/2009	X-RPL	08123456789	Nama ada angka; Kelas salah; No Telp beda
3	(kosong)	2024003	15/01/2008	X-TKJ	08521234432	Nama kosong, referensi tidak tersedia
4	Andi Wijaya	2024001	12/05/2008	X-TKJ	08123456789	Duplikat dari Baris 1
5	Dewi Sartika	2024005	22/03/2010	XTKJ	08123456781	Format kelas tidak konsisten
6	Eko Prasetyo	2024006	05/12/2007	X-TKJ	08133445	No Telp hanya 8 digit
7	Fani Rahayu	2024007	2008-07-15	X-TKJ	08133344455	Format tanggal tidak konsisten
8	Hendra Kusuma	2024002	01/11/2004	X-TKJ	08593829485	NIS duplikat dengan Baris 2
9	Gita Sari	2024009	05/12/2007	X-TKJ	08133344455	Tidak ada masalah

Hasil Pembersihan Data:

No	Nama (Setelah)	NIS	Tgl Lahir	Kelas	No Telp	Tindakan
1	Andi Wijaya	2024001	12/05/2008	X-TKJ	08123456789	✓ Bersih
2	Budi Santoso	2024002	10/10/2009	X-TKJ	08199867766	✏ Diedit
3	(kosong)	2024003	15/01/2008	X-TKJ	08521234432	■ Ditandai
4	[dihapus]	2024001	12/05/2008	X-TKJ	08123456789	✕ Dihapus

5	Dewi Sartika	2024005	22/03/2010	X-TKJ	08123456781	✏ Diedit
6	Eko Prasetyo	2024006	05/12/2007	X-TKJ	08133344455	✏ Diedit
7	Fani Rahayu	2024007	15/07/2008	X-TKJ	08133344455	✏ Diedit
8	Hendra Kusuma	2024008	01/11/2004	X-TKJ	08593829485	✏ Diedit
9	Gita Sari	2024009	05/12/2007	X-TKJ	08133344455	✓ Bersih

Keterangan: ■ Hijau = Bersih ■ Biru = Diedit ■ Merah = Dihapus ■ Kuning = Ditandai

G. Contoh Kasus pada Data Lain

Prinsip pembersihan data berlaku universal. Berikut adalah contoh penerapan pembersihan data pada dua jenis data yang umum ditemukan di dunia kerja:

Contoh 1 — Pembersihan Data Produk Toko

Data produk toko yang telah melalui proses validasi dan verifikasi kemudian dibersihkan dengan tindakan yang sesuai:

Kode	Nama Produk	Harga	Stok	Masalah	Tindakan
PRD-001	Buku Tulis A5	Rp 5.000	50	Tidak ada masalah	✓ Bersih
PRD-002	(kosong)	Rp 12.000	30	Nama kosong, nilai benar tidak diketahui	■ Ditandai
PRD-003	Pulpen Hitam	Rp 0	20	Harga 0 — seharusnya Rp 3.500	✏ Diedit
PRD-004	Penghapus	Rp 3.000	-5	Stok negatif — tidak valid	✏ Diedit
prd-005	Rautan Pensil	Rp 4.500	15	Format kode salah	✏ Diedit
PRD-006	Kertas HVS	Rp 8.000	100	Tidak ada masalah	✓ Bersih
PRD-001	Buku Tulis A5	Rp 5.000	50	Duplikat dari PRD-001 baris pertama	✕ Dihapus

Contoh 2 — Pembersihan Data Pegawai

Data pegawai yang telah diverifikasi dengan dokumen KTP kemudian dibersihkan berdasarkan hasil perbandingan:

ID	Nama (Sistem)	Nama (Benar)	Tgl Lahir (Sistem)	Tgl Lahir (Benar)	Masalah	Tindakan
P-001	Ahmad Fauzi	Ahmad Fauzi	15/03/1995	15/03/1995	Tidak ada masalah	✓ Bersih
P-002	Siti Nurhaliza	Siti Nur Haliza	22/07/1998	22/07/1998	Nama berbeda dengan KTP	✏ Diedit
P-003	Rudi Hermawan	Rudi Hermawan	10/01/1990	10/05/1990	Bulan lahir berbeda dengan KTP	✏ Diedit
P-004	(kosong)	Dewi Kusuma	05/06/1997	05/06/1997	Nama kosong, referensi ada	✏ Diedit
P-005	Budi Santoso	Budi Santoso	29/02/2001	(kosong)	Tgl lahir tidak valid (Feb 29 non-kabisat), referensi tidak ada	■ Ditandai

H. Langkah-Langkah Pembersihan Data

Pembersihan data harus dilakukan secara sistematis mengikuti langkah-langkah berikut agar setiap tindakan tepat sasaran dan tidak merusak data yang sudah benar:

1 Kumpulkan Seluruh Hasil Pemeriksaan Sebelumnya

Pastikan laporan hasil identifikasi, validasi, dan verifikasi sudah tersedia secara lengkap. Ketiga laporan ini menjadi panduan utama dalam menentukan tindakan pembersihan yang tepat untuk setiap entri data.

2 Tangani Data Duplikat Terlebih Dahulu

Identifikasi dan hapus semua data duplikat sebelum melakukan tindakan lain. Sebelum menghapus, pastikan bahwa entri yang akan dihapus benar-benar merupakan duplikat dan bukan entri yang berbeda dengan kesamaan yang kebetulan. Pastikan entri yang asli dan valid dipertahankan, sementara salinan duplikat dihapus. Menangani duplikat lebih awal mencegah kebingungan pada langkah berikutnya

3 Edit Data yang Dapat Diperbaiki

Perbaiki entri yang memiliki kesalahan format, nilai tidak valid, atau ketidaksesuaian kecil dengan referensi, selama nilai yang benar sudah diketahui secara pasti. Setiap perubahan nilai harus didasarkan pada data referensi yang sah atau aturan yang telah ditetapkan. Jangan mengubah nilai berdasarkan asumsi atau perkiraan tanpa dasar yang jelas.

4 Tandai Data yang Memerlukan Konfirmasi

Berikan tanda pada entri yang belum dapat diselesaikan atau yang nilai benarnya belum diketahui, karena membutuhkan informasi tambahan atau keputusan dari pihak yang berwenang. Catat secara jelas masalah yang ada dan pihak mana yang perlu dikonfirmasi..

5 Konfirmasi Data yang Sudah Bersih

Verifikasi kembali bahwa entri yang tidak memerlukan perubahan memang benar-benar bersih dengan mencocokan ulang terhadap aturan validasi dan data referensi yang tersedia. Berikan status ‘Data Bersih’ Secara eksplisit.

6 Verifikasi Ulang Hasil Pembersihan

Setelah seluruh tindakan pembersihan dilakukan, lakukan pemeriksaan akhir untuk memastikan tidak ada kesalahan baru yang muncul akibat proses pembersihan itu sendiri.

7 **Dokumentasikan Seluruh Perubahan**

Catat setiap perubahan yang dilakukan: entri mana yang diubah, nilai lama, nilai baru, alasan perubahan, dan sumber referensi yang digunakan. Dokumentasi ini penting untuk keperluan audit dan pelaporan.

I. Hal-Hal yang Perlu Diperhatikan dalam Pembersihan Data

Pembersihan data adalah proses yang sensitif karena melibatkan perubahan langsung pada data. Berikut adalah hal-hal penting yang harus selalu diperhatikan agar proses pembersihan berjalan dengan baik dan aman:

■ Selalu Buat Cadangan Data (Backup)

Sebelum memulai proses pembersihan, selalu buat salinan cadangan dari data asli. Jika terjadi kesalahan dalam proses pembersihan, cadangan ini memungkinkan pemulihan data ke kondisi semula.

■ Catat Semua Perubahan

Setiap perubahan yang dilakukan harus didokumentasikan dengan detail: entri mana, kolom mana, nilai lama, nilai baru, dan alasannya. Dokumentasi ini disebut **data audit trail** dan sangat penting untuk keperluan pertanggungjawaban.

■ Jangan Mengubah Data Tanpa Dasar

Setiap perubahan nilai harus memiliki dasar yang jelas — baik dari data referensi, aturan validasi, atau keputusan yang terdokumentasi. Mengubah nilai berdasarkan asumsi atau intuisi tanpa dasar yang dapat diverifikasi adalah praktik yang tidak dapat diterima.

■ Libatkan Pihak yang Berwenang

Untuk data yang penting dan sensitif, keputusan pembersihan sebaiknya tidak dilakukan secara sepihak. Libatkan pihak yang berwenang seperti kepala administrasi, wali kelas, atau manajer data untuk konfirmasi nilai yang benar sebelum perubahan dilakukan.

■ Pembersihan adalah Proses Berkelanjutan

Pembersihan data bukan merupakan kegiatan satu kali, melainkan proses yang perlu dilakukan secara berkala. Data baru yang masuk ke sistem harus selalu melalui proses identifikasi, validasi, verifikasi, dan pembersihan sebelum digunakan.

■ Penghapusan Data adalah Tindakan Terakhir

Penghapusan data harus menjadi pilihan terakhir dan hanya dilakukan ketika tidak ada cara lain untuk menyelamatkan atau memperbaiki data tersebut. Pertimbangkan selalu apakah menandai data lebih aman daripada menghapusnya secara permanen.

J. Ringkasan

1	Pembersihan data adalah tahap terakhir dalam siklus pengolahan data yang bertujuan menghasilkan data yang **bersih, akurat, lengkap, konsisten, dan siap digunakan**.
2	Terdapat empat jenis tindakan pembersihan: **Data Bersih** (tidak ada masalah), **Data Diedit** (ada kesalahan yang bisa diperbaiki), **Data Dihapus** (duplikat atau tidak bisa diperbaiki), dan **Ditandai** (perlu konfirmasi lebih lanjut).
3	Pemilihan tindakan harus didasarkan pada kondisi data: apakah nilai yang benar sudah diketahui, apakah data merupakan duplikat, dan apakah data sama sekali tidak dapat dipulihkan. **Jangan menghapus atau mengedit data berdasarkan asumsi** tanpa konfirmasi dari sumber referensi yang dapat dipertanggungjawabkan
4	Pembersihan data sepenuhnya **bergantung pada hasil tiga tahap sebelumnya** — identifikasi, validasi, dan verifikasi — sebagai panduan tindakan yang tepat.
5	Setiap tindakan yang diambil dalam pembersihan data harus didasarkan pada referensi yang sah dan didokumentasikan secara lengkap, termasuk nilai lama, nilai baru, dan alasan perubahan, untuk keperluan audit dan penelusuran di kemudian hari
6	Hasil akhir pembersihan data adalah kumpulan data yang bersih, lengkap, akurat dan konsisten yang siap digunakan sebagai dasar analisis dan pengambilan keputusan yang andal.
7	Data duplikat harus ditangani terlebih dahulu sebelum melakukan tindakan lain, untuk mencegah kebingungan dan memastikan entri yang asli tetap dipertahankan